

ComplexBench - перевод аннотации и конспект (RU)

Перевод аннотации (смысловой)

Следование инструкциям - одна из базовых возможностей больших языковых моделей (LLM).

По мере роста их качества LLM всё чаще применяют для работы со сложными человеческими инструкциями

в реальных сценариях. Поэтому оценка способности LLM следовать сложным инструкциям становится критически важной.

Существующие бенчмарки в основном описывают разные типы ограничений в инструкциях, но

недооценивают композицию ограничений - неизбежную часть сложных инструкций.

Чтобы закрыть этот пробел, авторы предлагают ComplexBench - бенчмарк для комплексной оценки того,

как LLM следуют инструкциям, составленным из множества ограничений.

В работе вводится иерархическая таксономия сложных инструкций:

- 4 типа ограничений
- 19 измерений (dimensions) ограничений
- 4 типа композиции (Single / And / Chain / Selection) + вложенные структуры

Датасет собран вручную. Для надёжной оценки авторы дополняют LLM-оценщики правилами,

которые проверяют, удовлетворяет ли ответ каждому ограничению и композиции.

Итоговый балл агрегируется с учётом структуры зависимостей, заданной типом композиции.

ComplexBench выявляет заметные слабые места современных LLM при работе с такими инструкциями.

Ключевые идеи, которые можно забрать в практику

- 1) Композиция важна: «AND + шаги + ветвление» труднее, чем просто список требований.
- 2) Оценка тоже должна быть структурной: нельзя просто «усреднить галочки» - есть зависимости (например, шаги).
- 3) Rule-augmented оценка (правила + LLM-оценщик) ближе к инженерной реальности: часть проверок должна быть детерминированной.

Как применять в AI-First разработке

- Формализуйте требования как контракт: входы/выходы, шаги, условия ветвления, критерии приёмки.
- Отдельно фиксируйте «ограничения формата» (формат/длина/язык), «семантики» (что должно быть сказано) и «utility/helpfulness» (тон, полезность, полнота).
- Для интеграции в pipeline делайте упор на quality gates: тесты/линтеры/проверки формата/бенчмарки.