

IFScale - перевод аннотации и конспект (RU)

Перевод аннотации (смысловой)

Производственные LLM-системы должны устойчиво соблюдать десятки или даже сотни инструкций одновременно.

Однако возможности LLM по следованию инструкциям при высокой «плотности» требований изучены плохо:

существующие бенчмарки обычно проверяют 1-несколько инструкций.

Авторы вводят IFScale - простой бенчмарк из 500 инструкций на включение ключевых слов

в задаче написания бизнес-отчёта. Это позволяет измерять, как качество следования инструкциям

ухудшается при росте их количества.

В работе оценены 20 современных моделей (несколько провайдеров).

Результат: даже лучшие модели достигают порядка ~68% точности при максимальной плотности (500 инструкций).

Анализ показывает:

- корреляцию с размером модели и «способностью рассуждать»;
- 3 типа деградации (пороговая / линейная / экспоненциальная);
- смещение к более ранним инструкциям (primacy);
- разные классы ошибок (пропуски и модификации).

Ключевые идеи для практики

1) Инструкции «не равны»: часть требований модель будет терять при перегрузе.

2) Порядок важен: то, что в начале, соблюдается чаще.

3) С ростом количества требований растёт вариативность (нестабильность результата).

Как применять в AI-First разработке

- Декомпозируйте: «список на 200 пунктов» лучше превратить в многошаговый сценарий с проверками.
- Ставьте жёсткие (must) и мягкие (should) требования отдельно.
- Автоматизируйте контроль: парсинг вывода, статпроверки, тесты, бенчи, DoD.
- Если правило критично - продублируйте его в форме проверки/валидатора, а не только в тексте промпта.